



Inteligencia Artificial

III. Árboles de decisión: Clasificación

Tarea 3

Clasificación automática de los tipos de cáncer

Con el notebook que realizamos en clase sobre los tipos de cáncer (BRCA, COAD, KIRC, LUAD, PRAD) usando el clasificador KNN, realice ahora lo siguiente:

1. Ejecute todas las celdas para cargar los datos y tenerlos listos para el modelo.
En la barra de menús: **Run->Run All Cells**
2. Agregue un título con una celda de *Markdown*
`<h1>Árboles de decisión: clasificación</h1>`
3. Genere un modelo de árbol de clasificación con los siguientes parámetros:
criterion= "entropy", random_state= 456
4. Entrene el modelo (Xtrain) y haga las predicciones con los datos de prueba (Xtest).
5. Obtenga la exactitud, el R2 score, los errores (MAE, MSE, RMSE) y la matriz de confusión del modelo.
6. Genere y exporte el diagrama del árbol con los parámetros:
 - figsize=(30, 16)
 - feature_names =range(1,8),
 - class_names = label_encoder.classes_,

feature_names son los nombres de las características del dataset pero como aplicamos componentes principales, los valores que se revisan son los que tenga en cada uno de los 7 componentes principales.

class_names son las categorías que dará como respuesta el modelo, se requiere que estén **ordenadas alfabéticamente** pero cuando las codificamos en el modelo anterior quedaron ordenadas.
7. Muestre el árbol en formato de texto.
8. Revise la importancia de los predictores.
9. Compare la clasificación real contra la predicción del modelo (Grafico en 2d de los puntos usando colores para indicar el tipo de cáncer)
***nota:** del gráfico 2d del modelo anterior solo cambia:

```
for i in np.unique(y_pred):  
    ax[1].scatter(  
        x = Xtest[y_pred == i, 0],  
        y = Xtest[y_pred == i, 1],  
        c = plt.rcParams['axes.prop_cycle'].by_key()['color'][i],  
        marker = 'o',
```



```

edgecolor = 'black',
label= f"Grupo {i}"
)

```

10. Realice una búsqueda por validación cruzada con el objeto GridSearchCV para analizar si usando una poda del árbol el modelo mejora. Use los siguientes parámetros:

```

param_grid = {'max_features': [None, 'log2', 'sqrt'],
'ccp_alpha': [0, 0.001, 0.002, 0.003, 0.004, 0.005, 0.006, 0.007, 0.008, 0.009, .01],
'max_depth': [3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15],
'criterion': ['gini', 'entropy', 'log_loss']}

```

11. Revise cual fue la mejor configuración encontrada (grid.best_params_) y muestre su profundidad y número de hojas.

12. Repita los pasos 5-9 con el modelo actual.

Como podrá notar el “mejor modelo” tiene menor precisión, pero también menor profundidad (menor complejidad y mayor rapidez) esto es porque en el análisis el algoritmo detecto que no tenia sentido aumentar 2 niveles solo por mejorar la exactitud en 0.63%. Esto lo puede comprobar si ejecuta de nuevo la poda quitando a “gini” de la lista de parámetros.

13. Llene la siguiente tabla de Excel y agréguela como imagen o hágala en el notebook con HTML.

Métricas de comparación	KNN	Árboles de decisión	
		Entropy	Mejor modelo Gini
% Exactitud			
R2 score			
MAE			
MSE			
RMSE			

Como podrá notar KNN tuvo mejor exactitud, pero recuerde que ese modelo implica almacenar todo el conjunto de entrenamiento y al pedirle las nuevas predicciones tiene que ejecutarse todo el algoritmo KNN en cambio el modelo de árbol ocupa muy poco espacio y la ejecución es instantánea.