



Inteligencia Artificial

III. Árboles de decisión: regresión

Tarea 4

Predicción del precio de autos

Con el repositorio CarPrice_Assignment.csv que está disponible en el siguiente enlace:

<https://www.kaggle.com/datasets/hellbuoy/car-price-prediction>

Realice lo siguiente en un Notebook de Jupyter:

1. Cargue los datos en Python usando Pandas y muestre los primeros 10 registros
2. Muestre las dimensiones del dataframe (# renglones, #columnas)
3. Las columnas doornumber y cylindernumber tienen su valor con letra en inglés, convierta estas columnas a numéricas.
`replace(('zero','one','two','three','four','five','six','seven','eight','twelve'),
(0,1,2,3,4,5,6,7,8,12))`
4. Muestre las estadísticas (media, desv est, cuartiles, max).
5. Indique el número de valores faltantes por columna del dataframe.
6. Muestre el tipo de todas las características (columnas) del dataframe.
7. Verifique que no hay renglones duplicados
`df.duplicated().sum()`
8. Realice el histograma y el diagrama de bigotes del precio.
9. Como podrá observar la marca está incluida en el nombre del auto, extráigala con el siguiente código

```
Company_Name = df["CarName"].apply(lambda x: x.split(" ")[0])  
df.insert(2,"CompanyName",Company_Name)  
  
# Now we can drop the CarName Feature.  
df.drop(columns=["CarName"],inplace=True)  
df.head()
```
10. Verifique los valores únicos de la marca
`df["CompanyName"].unique()`
11. Hay algunas marcas con errores por ejemplo maxda y mazda o vw y volkswagen. Ejecute el siguiente remplazo para solucionarlo:

```
replace(('maxda','porcshce','toyouta','vokswagen','vw'),  
( 'mazda','porsche','toyota','volkswagen','volkswagen'))
```



12. A partir de la marca y del precio promedio de cada marca agregue una columna que indique la gama del automóvil (baja, media, alta) con el siguiente código:

```
z = round(df.groupby(["CompanyName"])["price"].agg(["mean"]), 2).T
z
```

En la salida anterior, obtenemos el precio promedio de cada compañía de automóviles individual


- i) Primero se agrupa la información del dataframe por marca (CompanyName)
- ii) Se trabaja con la columna Price
- iii) agg es el equivalente en Python al aggregate de MongoDB.
A la salida anterior (Price agrupado por marca) le calcula el promedio (mean)
- iv) El resultado se redondea a 2 decimales round(...,2)
- v) Se obtiene la transpuesta .T para que el resultado quede como renglón (opcional)

Ahora tenemos que agregar estos valores promedio en una nueva columna en nuestro conjunto de datos.

```
df = df.merge(z.T, how="left", on="CompanyName")
```

merge es el equivalente en Python al inner join de SQL, how="left" indica que es left join y on indica la columna por la que se relacionan

LEFT JOIN



Se realiza el agrupamiento en cubetas (databinning)

```
bins = [0, 10000, 20000, 40000]
cars_bin = ['Budget', 'Medium', 'Highend']
df['CarsRange'] = pd.cut(df['mean'], bins, right=False, labels=cars_bin)
df.head()
```

13. Elimine las columnas car_ID, enginelocation y symboling ya que una solo es un identificador, la ubicación del motor no es importante y la otra no aporta información valiosa al modelo.

14. Realice los histogramas de las columnas categóricas vs Precio junto con los gráficos de dispersión (scatterplot) de las columnas numéricas vs Precio.

```
plt.figure(figsize=(12, 30))
plt.subplot(8, 3, k + 1)
```



15. Realice el diagrama de bigotes del precio respecto las siguientes características:

```
k = 0
plt.figure(figsize=(15, 36))
columns=["CompanyName","fueltype","carbody","enginetype","CarsRange"]
for col in columns:
    plt.subplot(8, 3, k + 1)
    sns.boxplot(x=col,y="price",data=df)
    plt.xticks(rotation=90)
    plt.title(f"Car Price by {col}", pad=10, fontweight="black", fontsize=12)
    k += 1
plt.tight_layout()
```

16. Elimine las columnas con alta cardinalidad excepto *enginetype* pues esta característica tiene un alto impacto en nuestra variable objetivo.

17. Elimine las columnas de varianza baja (ninguna, pero ejecute la prueba).

18. Elimine las características que tienen una correlación mayor a **0.85**

19. Para cada una de las columnas categóricas (object, categorical) ejecute el siguiente código que calcula el precio promedio por categoría.

```
df[['fueltype','price']].groupby(['fueltype'], as_index = False).mean().sort_values(by = 'price', ascending = False)
```

- Para las columnas binarias remplace por 0 o 1 (fueltype, aspiration)
replace(("gas","diesel"),(0,1))
replace(("std","turbo"),(0,1))
- Para las columnas ordinales remplace por una escala numérica (CarsRange)
replace(("Budget","Medium","Highend"),(0,0.5,1))
- Para las columnas con menos de 9 categorías genere las columnas dummy en formato one-hot (recuerde ordenar las columnas alfabéticamente) (carbody, drivewheel, enginetype)
- Para el resto remplace por el valor promedio de cada categoría. (ninguna)

20. Aplique las pruebas del factor de inflación de la varianza (**VIF**) para eliminar en cada iteración la característica con el mayor coeficiente VIF hasta que todas queden con un valor inferior a 5. Debe ignorar la columna objetivo price y las columnas 'horsepower' y 'carwidth' pues son de gran importancia para el modelo. También debe ignorar todas las columnas dummy, pues marcarán infinito.

```
ignorecolumns=['price', 'horsepower', 'carwidth', 'convertible', 'hardtop', 'hatchback', 'sedan', 'wagon', '4wd', 'fwd', 'rwd', 'dohc', 'dohcv', 'l', 'ohc', 'ohcf', 'ohcv', 'rotor']
X = df.drop(ignorecolumns,axis=1)
```

21. Muestre los primeros 10 renglones del dataframe actual y sus dimensiones.



22. Recuerde que parte del proceso de la Minería de Datos es involucrarse del negocio, por lo que puede consultar los siguientes enlaces para conocer a que se refieren las características con las que trabajaremos:

- **Fueltype** tipo de combustible gasolina o disel
- **Carbody** tipo de carrocería
<https://www.motorpasion.com/espaciotoyota/sabes-que-tipo-carroceria-lleva-tu-coche-te-explicamos-facil-ejemplos>
 - **carbody hardtop**
https://es.wikipedia.org/wiki/Tipo_de_carroceria
- **drive Wheel** rueda motriz
<https://www.jeep.com.mx>
- **engine type** tipo de motor
 dohc (Dual OverHead Cam), dohcvc (Dual OverHead Cam and Valve), I (L engine), ohc (OverHead Cam), ohcv (OverHead Cam and Valve F engine), ohcv (OverHead Cam and Valve) and rotor (Rotary engine)
 - dohc
<https://www.civictmotors.com/what-does-dohc-mean/>
 - ohc, dohcvc, ohcv
<https://www.pruebaderuta.com/que-es-un-motor-sv-ohv-sohv-y-dohc.php>
 - Motor en línea L
https://www.motociclismo.es/consejos/motores-en-linea-son-comparativa-con-otros-ecn_271167_102.html
 - rotor
<https://como-funciona.co/un-rotor/>
- **Horsepower** caballos de fuerza
<https://www.kia.com>

23. Separe los datos en 80% entrenamiento y 20% pruebas (Xtrain, Xtest, Ytrain, Ytest)

24. Genere un primer árbol de regresión con los siguientes parámetros y entrénelo:

modelo = DecisionTreeRegressor(random_state = 123)

25. Haga las predicciones con los datos de prueba.

26. Calcule el el R2 score y los errores (MAE, MSE, RMSE) de las predicciones.

27. Realice el grafico 2d para comparar el valor real contra las predicciones del modelo.

28. Realice el diagrama del árbol con los siguientes parámetros y con ayuda de GIMP o

Photoshop exporte el árbol a JPG

figsize=(120, 25)

feature_names = Xtest.columns



29. Muestre la información del 1er registro de prueba y haga un recorrido desde la raíz hasta la hoja que le corresponde para verificar que el precio coincide con predicciones[0]

```
pd.set_option('display.max_columns', None)
Xtest.head(1)
```

30. Realice una búsqueda por validación cruzada con el objeto GridSearchCV para analizar si usando una poda del árbol el modelo mejora. Use los siguientes parámetros:

```
param_grid = {'criterion': ["squared_error", "friedman_mse", "absolute_error", "poisson"],
              'max_features': [None, 'log2', 'sqrt', 'auto'],
              'ccp_alpha': [0, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1],
              }
```

31. Revise cual fue la mejor configuración encontrada (grid.best_params_) y muestre su profundidad y número de hojas para comprobar que el árbol que generó al inicio es el mejor posible para este ejercicio.